

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

Raspoznavanje dobne skupine pomoću linearne diskriminantne analize (LDA)

Jelena Banjanin

Petar Čolić

Petra Jagodić

Karlo Knežević

Ivo Majić

Boris Malvić

Zagreb, siječanj 2012.

SADRŽAJ

1. Projektni zadatak	1
1.1. Opis	1
1.2. Konceptualno rješenje	1
2. Teorijski opis korištenih postupaka	3
2.1. PCA	3
2.2. LDA	3
2.2.1. LDA s dva razreda	4
2.2.2. LDA s više razreda	5
2.3. Klasifikatori	8
2.3.1. kNN	8
2.3.2. SVM	9
3. Implementacija	13
4. Rezultati	14
4.1. Uzorci	14
4.1.1. Normalizacija uzoraka baze	14
4.1.2. Razredi uzoraka	15
4.1.3. Skup za učenje i ispitni skup	15
4.2. Rezultati učenja i ispitivanja	17
4.2.1. Optimalan potprostor transformacije PCA	17
4.2.2. Parametar k klasifikatora kNN, korištenjem euklidske udaljenosti	19
4.2.3. Parametri klasifikatora SVM s polinomijalnom jezgrenom funk-	
cijom	20
4.2.4. Parametri klasifikatora SVM s jezgrom radijalne bazne funkcije	22
4.2.5. Objektivnost apriorno definiranih dobnih granica	23
4.2.6. Broj okvira fotografije	24

4.3. Analiza rezultata	26
4.3.1. Klasifikator kNN	26
4.3.2. Klasifikator SVM s polinomijalnom jezgrenom funkcijom . .	27
4.3.3. Klasifikator SVM s jezgrom radijalne bazne funkcije	28
4.3.4. Moguća poboljšanja	28
5. Zaključak	29
6. Literatura	30

1. Projektni zadatak

1.1. Opis

Projektni je zadatak razviti sustav za određivanje starosti subjekta, pri čemu razlikujemo četiri dobne skupine:

- djeca do 13 godina
- adolescenti 13 do 21 godina
- odrasle osobe 21 do 60 godina
- starije osobe 60+ godina

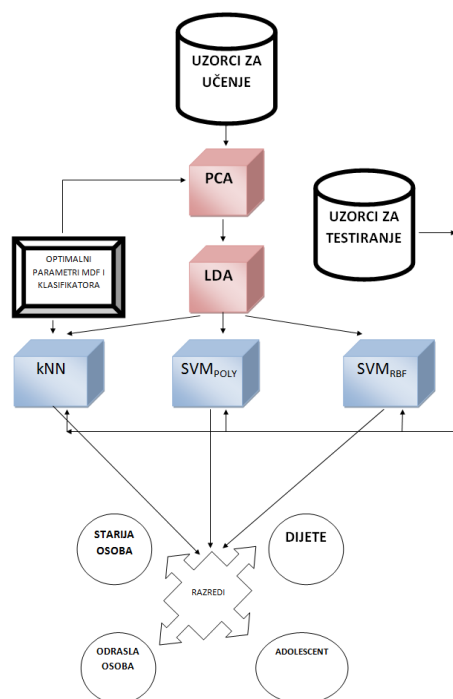
Zbog edukativnog karaktera projekta, prilikom njegove izrade obvezno je koristiti metodu linearne diskriminantne analize (LDA). Za učenje klasifikatora i provjeru uspješnostina raspolaganju su slike iz baza „Face and Gesture Recognition Research Network Aging Database“ (FG-NET) i „Longitudinal Face Database/MORPH“.

1.2. Konceptualno rješenje

Pri izradi sustava korištene su sljedeće metode (respektivno):

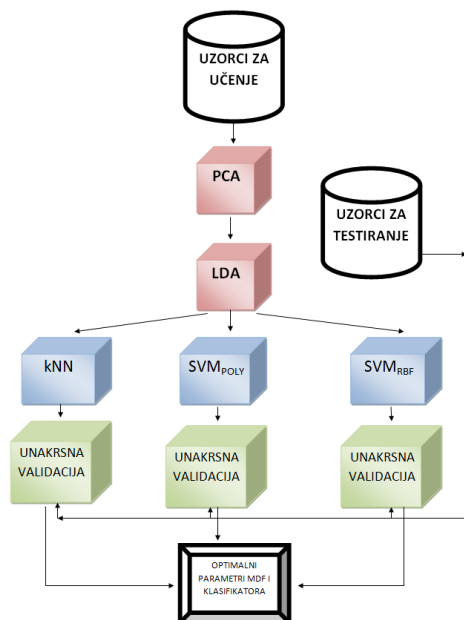
- Analiza glavnih komponenti (PCA)
- Linearna diskriminantna analiza (LDA)
- Stroj s potpornim vektorima (SVM)
- K najbližih susjeda (KNN)

Ulaz u sustav je normalizirana slika lica koja se u prvom koraku razlama na jedan, četiri ili šesnaest dijelova. Potom se svaki dio obrađuje analizom glavnih komponenta a nad dobivenim svojstvenim vektorima vrši se linearna diskriminantna analiza. Rezultat analize (trodimenzionalni vektor) potrebno je SVM ili KNN klasifikatorom razvrstati u jedan od četiri ciljna razreda. Na slici 1.1 prikazan je konceptualni tok programskog rješenja. [5] [1] [3] [4]



Slika 1.1: Grafički prikaz konceptualnog rješenja

Za pronalaženje optimalnih parametara pojedinih komponenti sustava, je nad skupom za testiranje provedena unakrsna validacija. Na slici 1.2 je grafički prikazan tok unakrsne validacije.




Slika 1.2: Grafički prikaz unakrsne validacije

2. Teorijski opis korištenih postupaka

2.1. PCA

Analiza glavnih komponenti je matematički postupak čija je svrha redukcija dimenzionalnosti. Za zadani skup numeričkih vrijednosti cilj je pronaći manji skup vrijednosti. Te vrijednosti su linearna kombinacija originalnih vrijednosti i nazivaju se glavne komponente. PCA najprije pronalazi jednak broj glavnih komponenti koliko ima i originalnih vrijednosti, zatim se ovisno o primjeni zadržava prvih glavnih komponenti, gdje je . Taj proces je ekvivalentan zamjeni originalnih vrijednosti njihovim ortogonalnim projekcijama u k -dimenzionalnom prostoru. Analiza glavnih komponenti se tradicionalno obavlja na kvadratnoj simetričnoj kovarijantnoj matrici.



Slika 2.1: Analiza glavnih komponenti: Originalne vrijednosti i glavne komponente

2.2. LDA

Linearna diskriminantna analiza (ili Fisherova linearna diskriminanta) je statistička metoda klasifikacije objekata u međusobno isključive razrede temeljem objektu pripadnih značajki. Cilj ove metode je d -dimenzionalni vektor značajki \vec{x} reducirati na jednu dimenziju ($R^d \rightarrow R^1$) te ga tada upotrijebiti za klasifikaciju. Kako bi uspješno

reducirali vektor značajki moramo naći pravac za smjerom \vec{w} na koji možemo projicirati d -dimenzionalne uzorke \vec{x}_i ($i = 1, 2, \dots, n$) na način da uzorci budu maksimalno separabilni.

2.2.1. LDA s dva razreda

Pretpostavimo da imamo skup od n d -dimenzionalnih uzoraka $(\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n)$ od kojih n_1 uzoraka čini podskup D_1 (koji pripadaju razredu ω_1) te n_2 uzoraka koji čini podskup D_2 (koji pripadaju razredu ω_2). Sada možemo tvoriti linearnu kombinaciju komponenti vektora \vec{x} s \vec{w}

$$y_i = \vec{w}^T \cdot \vec{x}_i \quad i = 1, 2, \dots, n \quad (2.1)$$

kojom dobivamo odgovarajući skup od n uzoraka y_1, y_2, \dots, y_n pri čemu svaki y_i odgovara projekciji odgovarajućeg vektora \vec{x}_i na pravac (u smjeru \vec{w}). Kako želimo da projekcije na pravac određen s \vec{w} budu takve da su dobro odvojive naš cilj je naći smjer vektora \vec{w} kojim to najbolje postizemo. Kriterij koji pri tome koristimo je mjera odvojenosti između projiciranih uzoraka (razlika srednjih vrijednosti projiciranih uzoraka).

$$\vec{m}_i = \frac{1}{n_i} \sum_{\vec{x} \in D_i} \vec{x} \quad i = 1, 2 \quad (2.2)$$

$$\tilde{m}_i = \frac{1}{n_i} \sum_{y \in Y_i} y \quad i = 1, 2 \quad (2.3)$$

$$\tilde{m}_i = \vec{w}^T \cdot \vec{m}_i \quad (2.4)$$

Da bismo dobili dobro odvajanje projiciranih uzoraka želimo da ‘udaljenost’ između srednjih vrijednosti projiciranih točaka bude relativno velika u odnosu na neku mjeru standardne devijacije za svaki razred. Za to uzimamo mjeru raspršenosti projiciranih uzoraka unutar razreda:

$$\tilde{s}_i^2 = \sum_{y \in Y_i} (y - \tilde{m}_i)^2 \quad (2.5)$$

Fisherova linearna diskriminanta određuje da linearna funkcija $\vec{w}^T \vec{x}$ za koju je kriterijska funkcija $J(\vec{w})$ maksimalna vodi najboljem razdvajanju između projiciranih skupova.

$$J(\vec{w}) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{s}_1^2 + \tilde{s}_2^2} \quad (2.6)$$

2.2.2. LDA s više razreda

Pretpostavimo da postoji skup od n d -dimenzionalnih uzoraka $(\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n)$, od kojih n_1 uzoraka čini skup D_1 (koji pripadaju razredu ω_1), n_2 uzoraka čini skup D_2 (koji pripadaju razredu ω_2), odnosno n_k uzoraka čini skup D_c (koji pripadaju razredu ω_c). Generalizirana višestruka linearna analiza uključuje $c - 1$ diskriminantnih funkcija, odnosno radi se projekcija iz d -dimenzionalnog prostora u $c - 1$ -dimenzionalni prostor. Višestruka diskriminantna analiza postupak je učenja odabira jedne od $c - 1$ diskriminantnih funkcija te težinskih vektora koji će u $c - 1$ dimenzionalnom prostoru usmjeriti diskriminantnu (projekcijsku) hiperravninu. Zahtjevi kod višestruke linearne analize ostaju isti kao i kod LDA s dva razreda: udaljenost srednjih vrijednosti projiciranih točaka (n -dimenzionalnih uzoraka) mora biti relativno velika u odnosu na mjeru raspršenosti između projiciranih razreda. Drugim riječima, zahtjev je da uzorci različitih razreda, u projekcijskoj hiperravnini, budu maksimalno udaljeni (zbog separatibilnosti), ali da raspršenje projiciranih uzoraka unutar razreda bude maleno (udaljenost sličnih uzoraka mora biti malena). Cilj je formirati takvu kriterijsku funkciju koja će dati rješenje kad je ostvaren navedeni zahtjev. U svrhu formiranja kriterijske funkcije, definiramo nekoliko pomoćnih funkcija.

Generalizirana matrica raspršenosti unutar razreda, S_w

$$S_W = \sum_{i=1}^c S_i \quad (2.7)$$

$$S_i = \sum_{x \in D_i} (x - m_i)(x - m_i)^T \quad (2.8)$$

$$m_i = \frac{1}{n_i} \sum_{x \in D_i} x \quad (2.9)$$

Simbol S_i označava matricu raspršenosti unutar razreda ω_i , simbol m_i označava srednju vrijednost uzoraka iz skupa D_i (razreda ω_i).

Ukupan vektor srednjih vrijednosti, m

$$m = \frac{1}{n} \sum_x x = \frac{1}{n} \sum_{i=1}^c n_i m_i \quad (2.10)$$

Simbol n_i označava broj uzoraka u skupu D_i (razredu ω_i).

Ukupna matrica raspršenosti, S_T

$$S_T = \sum_x (x - m)(x - m)^T \quad (2.11)$$

Jednadžba (2.11) može se raspisati:

$$S_T = \sum_{i=1}^c \sum_{x \in D_i} (x - m_i + m_i - m)(x - m_i + m_i - m)^T \quad (2.12)$$

$$S_T = \sum_{i=1}^c \sum_{x \in D_i} (x - m_i)(x - m_i)^T + \sum_{i=1}^c \sum_{x \in D_i} (m_i - m)(m_i - m)^T \quad (2.13)$$

$$S_T = S_W + \sum_{i=1}^c n_i (m_i - m)(m_i - m)^T \quad (2.14)$$

Drugi član u jednadžbi (2.14) predstavlja poopćenu matricu raspršenosti između razreda, S_B . Dakle, matrica S_T , može se zapisati kao

$$S_T = S_W + S_B \quad (2.15)$$

Poopćena matrica raspršenosti između razreda, S_B

$$S_B = \sum_{i=1}^c n_i (m_i - m)(m_i - m)^T \quad (2.16)$$

Projekcijom iz d -dimenzionalnog prostora u $c - 1$ - dimenzionalni prostor postiže se uporabom (jednom od mogućih) $c - 1$ diskriminantnih funkcija, oblika:

$$y_i = w_i^T x, \quad i = 1, 2, \dots, c - 1 \quad (2.17)$$

Ukoliko se y_i promatra kao komponenta vektora Y i ukoliko se težinski vektori w_i promatraju kao stupci matrice W , tada se projekcija (2.17) transformira u:

$$Y = W^T x \quad (2.18)$$

Uzorci $(\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n)$ projiciraju se u odgovarajući skup uzoraka $(\vec{y}_1, \vec{y}_2, \dots, \vec{y}_n)$ koji također mogu biti opisani generaliziranom matricom raspršenosti unutar razreda,

vektorom srednjih vrijednosti, ukupnim vektorom srednjih vrijednosti te poopćenom matricom raspršenosti između razreda. Tada se matrice raspršenosti projiciranih uzoraka unutar i izvan razreda mogu napisati kao:

$$\tilde{S}_W = \sum_{i=1}^c \sum_{y \in Y_i} (y - \tilde{m}_i)(y - \tilde{m}_i)^T \quad (2.19)$$

$$\tilde{S}_B = \sum_{i=1}^c n_i (\tilde{m}_i - m)(\tilde{m}_i - m)^T \quad (2.20)$$

Može se pokazati da se jednađbe (2.19) i (2.20) mogu zapisati kao:

$$\tilde{S}_W = W^T S_W W \quad (2.21)$$

$$\tilde{S}_B = W^T S_B W \quad (2.22)$$

Jednađbe (2.21) i (2.22) pokazuju kako se matrice raspršenja unutar i izvan razreda transformiraju projekcijom u nižedimenzionalni prostor. Kada su definirani pojmovi raspršenja, može se napisati kriterijska funkcija:

$$J(W) = \frac{|\tilde{S}_B|}{|\tilde{S}_W|} \quad (2.23)$$

Traži se maksimum kriterijske funkcije (2.23) jer tada su zadovoljeni uvjeti koji su postavljeni u uvodu. Problem traženja i nalaženja pravokutne matrice W , koja maksimizira kriterijsku funkciju (2.23) težak je problem. Međutim, problem se može riješiti ukoliko se stupci optimalne matrice W prikažu kao generalizirani svojstveni vektori koji odgovaraju najvećim svojstvenim vrijednostima u (2.24).

$$S_B W_i = \lambda_i S_W W_i \quad (2.24)$$

Da se izbjegne računanje inverza matrice S_W i traženja svojstvene vrijednosti λ , mogu se tražiti svojstvene vrijednosti λ_i , kao korijeni karakterističnog polinoma (2.25).

$$|S_B - \lambda_i S_W| = 0 \quad (2.25)$$


Može se pokazati da je kriterijska funkcija (2.23) jednaka umnošku $c - 1$ karakterističnih vrijednosti vektora stupaca matrice W :

$$J(W) = \lambda_1 \lambda_2 \dots \lambda_{c-1} \quad (2.26)$$

Kada se pronađu karakteristične vrijednosti λ_i , uzima se najveća po iznosu λ_i i pomoću nje rješava se jednačba (2.27):

$$(S_B - \lambda_{max} S_W) \vec{w} = 0 \quad (2.27)$$

Dobiveni vektor \vec{w} predstavlja težinske koeficijente projekcijske hiperravnine u $c-1$ dimenzionalnom prostoru.



Slika 2.2: Linearna diskriminantna analiza u 2D

2.3. Klasifikatori

2.3.1. kNN

Završni dio procesa raspoznavanja dobnih skupina jest sama klasifikacija izlučenih značajki. Za to je vrlo pogodan 1-NN algoritam koji je zapravo poseban slučaj k -NN algoritma (engl. nearest neighbors) kada je vrijednost k jednaka 1. To je jedan od najjednostavnijih postupaka klasifikacije objekata u strojnom učenju koji se temelji na funkciji udaljenosti. Pretpostavimo da imamo skup od N uzoraka s poznatom klasifikacijom, gdje svaki uzorak pripada jednom od M razreda:

- $\{\vec{S}_1, \vec{S}_2, \dots, \vec{S}_N\}$ skup uzoraka s poznatom klasifikacijom
- $\omega_1, \omega_2, \dots, \omega_N$ - razredi

1-NN klasifikator će svrstati nepoznati uzorak \vec{x} u razred ω_k ako je najbliži uzorak s poznatom klasifikacijom \vec{S} element razreda ω_k , odnosno vrijedi:

$$D(\vec{S}_l, \vec{x}) = \min\{D(\vec{S}_l, \vec{x})\}, l = 1, 2, \dots, N \quad (2.28)$$

gdje je mjera udaljenosti (na primjer Euklidska, Mahalonibsova itd.).

Korake algoritma za klasifikaciju možemo opisati na sljedeći način:

1. Pronađi udaljenosti između uzorka nepoznate osobe i svih preostalih uzoraka iz skupa za učenje
2. Sortiraj udaljenosti od najmanje prema najvećoj
3. Na temelju prvih k udaljenosti odredi kojoj osobi pripada uzorak (u ovom slučaju $k = 1$ pa se uzima u obzir samo prva odnosno najmanja udaljenost)

Prednost ovakvog postupka prvenstveno je jednostavnost razumijevanja i primjene. Negativna je strana to što se razredi koji u skupu za učenje imaju više označenih članova od drugih razreda češće pojavljuju u skupini k najbližih susjeda te tako utječu na rezultate klasifikacije.


2.3.2. SVM

Stroj s potpornim vektorima (engl. Support Vector Machine) je binarni klasifikator koji konstrukcijom hiperravnine u visoko-dimenzionalnom prostoru stvara model koji predviđa kojem od dva razreda pripada novi uzorak. Osnovna ideja ove metode je konstruirati hiperravninu kao decisijsku plohu tako da je margina odvajanja razreda maksimalna.

U skupu za učenje imamo L vektora (točaka u D -dimenzionalnom prostoru), gdje svaki uzorak ima D atributa, odnosno komponenti vektora, te pripada jednom od dva razreda. Pretpostavlja se da su uзорci linearno odvojivi, što znači da možemo nacrtati pravac u koordinatnom sustavu s osima x_1 i x_2 za slučaj $D = 2$, odnosno hiperravninu za slučaj $D > 2$. Hiperravninu opisujemo izrazom $w * x + b = 0$, gdje je:

- w - normala hiperravnine
- $\frac{b}{||w||}$ - okomita udaljenost hiperravnine od ishodišta koordinatnog sustava.

Uzorci koji se u prostoru nalaze najbliže decizijskoj hiperravnini najteže se klasificiraju i zbog toga direktno utječu na optimalan položaj decizijske hiperravnine. Ti se uzorci nazivaju potporni vektori. Slika 2.3 prikazuje jednostavan primjer za slučaj dva linearno odvojiva razreda.



Slika 2.3: Slučaj dva linearno odvojiva razreda

Implementacija stroja s potpornim vektorima sada se svodi na odabir parametara w i b , takvih da ulazne podatke možemo opisati sljedećim izrazima:

$$w * x_i + b \geq 1, x_i \in \omega_1 \quad (2.29)$$

$$w * x_i + b \leq -1, x_i \in \omega_2 \quad (2.30)$$

To možemo objediniti u jedan uvjet:

$$y_i * (w * x_i + b) - 1 \geq 0 \quad (2.31)$$

gdje je $y_i \in \{1, -1\}$, ovisno o tome kojem razredu pripada uzorak x_i .

Tada su ravnine H_1 i H_2 na kojima leže potporni vektori određene sjedećim jednadžbama:

$$w * x_i + b = 1 \text{ za } H_1 \quad (2.32)$$

$$w * x_i + b = -1 \text{ za } H_2 \quad (2.33)$$

Ako želimo proširiti funkcionalnost stroja s potpornim vektorima na linearno neodvojive razrede, potrebno je ublažiti uvjete uvođenjem nenegativne vrijednosti ξ :


$$w * x_i + b \geq 1 - \xi_i \text{ za } x_i \in \omega_1 \quad (2.34)$$

$$w * x_i + b \geq -1 + \xi_i \text{ za } x_i \in \omega_2 \quad (2.35)$$

Kombinacijom ta dva izraza dobivamo jedinstveni uvjet:

$$y_i * (w * x_i + b) - 1 + \xi_i \geq 0, \xi_i \geq 0 \forall i \quad (2.36)$$

Ova metoda naziva se metoda meke margine (engl. soft margin method), a izvorno je nastala s idejom dozvoljavanja pogrešnog označavanja razreda prije samog postupka učenja. Na slici 2.4 prikazana je hiperravnina (pravac) kroz dva linearno neodvojiva razreda. Vidljiv je i uzorak s pogrešne strane hiperravnine zbog kojeg prostor nije linearno odvojiv. Mjera udaljenosti tog uzorka od pripadajućeg potpornog vektora jest ξ_i .



Slika 2.4: Slučaj dva linearno neodvojiva razreda

Do sada opisani (linearni) klasifikator zapravo se naziva klasifikator optimalne granice (engl. Maximum Margin Classifier). Stroj s potpornim vektorima je poopćeni klasifikator optimalne granice za nelinearnu klasifikaciju, sa primjenjenim jezgrenom trikom (engl. Kernel Trick). Ideja ovog postupka je povećanje dimenzionalnosti prostora uzoraka tako da se ulazni vektor značajki x_i zamijeni jezgrenom funkcijom $f(x_i)$

koja preslikava ulazni vektora iz n -dimenzionalnog u m -dimenzionalni prostor, pri čemu je $m > n$. U novom, m -dimenzionalnom, prostoru uzorci su linearno odvojivi.

Postoji nekoliko različitih jezgrenih funkcija u upotrebi od kojih su ovom projektu korištene dvije:

- Polinomna: $K(x_i, x_j) = (x_i^T * x_j + a)^b$
- RBF (engl. Radial basis function): $K(x_i, x_j) = e^{-\gamma * ||x_i - x_j||^2}, \gamma > 0$

Gaussova jezgra je jezgra s najširoom primjenom. Ona odgovara preslikavanju u beskonačno-dimenzionalni prostor. Sve što je linearno razdvojivo u početnom prostoru značajki, razdvojivo je i u prostoru određenom ovom jezgrom. Parametar γ određuje širinu „zvona“ Gaussove krivulje.

Stroj s potpunim vektorima je binarni klasifikator, što znači da može razvrstati neki nepoznati uzorak u jedan od dva razreda. Budući da mi razvrstavamo uzorke u 4 dobne skupine, pojavljuje se problem razvrstavanja uzoraka u 4 razreda. Postoje dva načina kako se problem klasifikacije uzoraka u više od dva razreda može riješiti:

1. Konstruirati n binarnih klasifikatora od kojih svaki svrstava uzorke ili u jedan od razreda ili u preostalih $n - 1$ razreda. Ovakav pristup se naziva „jedan-protiv-svih“ (engl. one vs. all)
2. Konstruirati $\frac{n*(n-1)}{2}$ binarnih klasifikatora od kojih svaki svrstava uzorke u jedan od dva razreda. Ovakav pristup naziva se „jedan-protiv-jednog“ (engl. one vs. one)

3. Implementacija

Programska implementacija izvedena je u programskom jeziku Python 2.7.2. Pritom su korišteni dodatni moduli [2]:

1. **NumPy** – omogućava korištenje naprednih matematičkih funkcija
2. **OpenCV** – omogućuje korištenje OpenCV 2.3.1 funkcionalnosti (PCA i SVM)
3. **Matplotlib** – omogućuje iscrtavanje grafova, korišteno pri izradi dokumentacije

main.py

Aplikacija se poziva iz modula **main**. U njemu se importa modul **klasifikator** te pozivom metoda pripadajuće klase postavlja parametre **brOkvira** i **dobneSkupine**, pokreće metode **doPCALDA()** i **trainKNN(k)** (ili **trainSVN()**) te ispisuje rezultate raspoznavnja/klasifikacije.

klasifikator.py

Modul **klasifikator** importa module **lda** i **knn** te implementira razred **AgeKlasifikator**.

lda.py

Unutar modula **lda** nalaze se dvije funkcije. Funkcija **LDACompute(uzorci, pripadnost)** računa LDA na temelju svih slika za učenje i njihovih pripadnosti razredima. Funkcija vraća tri najbolja svojstvena vektora dobivena linearnom diskriminantnom analizom. **LDAProject(uzorci, eigenvektori)** projicira slike za testiranje u prostor koji razapinju prije spomenuti svojstveni vektori.

knn.py

Modul **knn** sadrži klasu **KNN**. Metoda **train(k)** inicijalizira varijable **k**, **uzorci** i **pripadnost**, odnosno pohranjuje podatke o uzorcima i njihovoj pripadnosti u varijable razreda **KNN** u obliku pogodnom za uporabu. Metoda **predict()** za ulazni testni uzorak vraća pretpostavljeni razred.

4. Rezultati

4.1. Uzorci

U projektu su korištene fotografije dvije baze lica:

- FGNET – 937 fotografija
- MORPH – 1586 fotografija

4.1.1. Normalizacija uzoraka baze

Baze sadrže kolorirane ili sive fotografije naličja glave muške ili ženske osobe. Prije postupka MDF (engl. Most Discriminant Feature), serije analize glavnih komponenata (PCA) i linearne diskriminantne analize (LDA), sve fotografije moraju biti normalizirane da bi svojstva svih fotografija bila jednako vrednovana. Normalizacija se provodi u 2 koraka:

- detekcija i gruba normalizacija lica
- vađenje značajki i točna normalizacija lica

Karakteristike normaliziranih fotografija lica (Slika 4.1 i 4.2):

- jednake rezolucije
- sive fotografije
- prikaz lica (ne prikazuju se objekti koji nisu dio lica)
- oči osoba nalaze se na jednakoj visini u slici i centrirane su

Nakon provedene normalizacije fotografija, dobivene su fotografije rezolucije 128x128, što znači da su fotografije uzorci u 16384-dimenzionalnom prostoru. Vrijednosti značajki su vrijednosti sive razine svakog piksela slike predstavljene cijelim brojevima 0-255.



Slika 4.1: Normalizirano lice djeteta



Slika 4.2: Normalizirano lice starije osobe

4.1.2. Razredi uzoraka

Uzorci obe baze pripadaju jednom od 4 razreda: dijete, adolescent, odrasla osoba i starija osoba. Najprije je napravljena unija uzoraka obe baze, a zatim su uzorci razvrstani u 4 klasifikacijske mape. Broj uzoraka po mapama:

- mapa djece: 482 uzorka
- mapa adolescenata: 729 uzoraka
- mapa odraslih osoba: 1301 uzoraka
- mapa starijih osoba: 11 uzoraka

Inicijalno su uzorci razvrstani prema subjektivno određenim dobnim granicama navedenim u poglavlju 1.1. Najveći problem predstavlja neravnomjeran udio starijih osoba u skupu uzoraka (0.44%).

4.1.3. Skup za učenje i ispitni skup

U projektu je ispitivano nekoliko parametara:

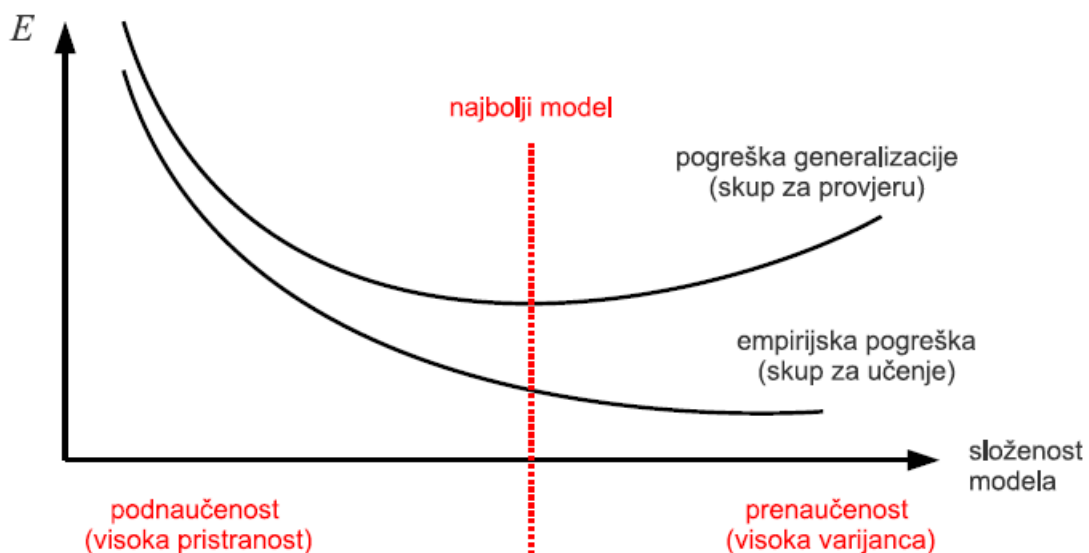
- optimalan potprostor transformacije PCA

- parametar k klasifikatora kNN, korištenjem euklidske udaljenosti
- parametri klasifikatora SVM s polinomijalnom jezgrenom funkcijom
- parametri klasifikatora SVM s jezgrom radijalne bazne funkcije
- objektivnost apriorno definiranih dobnih granica
- broj okvira fotografije

Da bi se odredili parametri i hiperparametri, korištena je metoda unakrsne validacije (Slika 4.3). Baza uzoraka podijeljena je na 2 skupa:

- skup za učenje, 1500 uzoraka
- skup za ispitivanje, 400 uzoraka

Odabrani su oni parametri koji su imali najveću točnost generalizacije na skupu za ispitivanje. Najprije je apriori određen optimalan prostor transformacije PCA ($D=100$), a zatim su se u 4 petlje varirali iznosi parametara i hiperparametara i odabrani su optimalni. Zatim se varirala dimenzionalnost transformacije PCA i postupak se ponavljao nekoliko puta. Objektivnost apriorno definiranih dobnih granica određivala se prikazom koloriranih uzoraka, nakon provođenja MDF postupka, u 3D prostoru, a boja je uniformno raspoređena po dobnim skupinama.



Slika 4.3: Graf smanjenja empirijske pogreške i pogreške general. kod unakrsne validacije

4.2. Rezultati učenja i ispitivanja

Najbolju točnost klasifikacije postigao je kNN klasifikator ($k=41$, $D_{PCA}=100$ ili $k=19$, $D_{PCA}=90$, broj okvira=4), od 76%. Klasifikator SVM, s polinomijalnom jezgrenom funkcijom postigao je najbolju točnost od 70% (stupanj polinoma=5, $C=2$, $\gamma = 14$, broj okvira=1). Klasifikator SVM, s jezgrom radijalne bazne funkcije postigao je najbolju točnost od 71% ($C=1$, $\gamma = 0.0001$, broj okvira=1). Pošto je kNN klasifikator imao najmanju pogrešku generalizacije, isti je odabran kao konačan klasifikator u sustavu.

4.2.1. Optimalan potprostor transformacije PCA

Dimenzionalnost prostora transformacije PCA varirana je u rasponu [20,1000], po logaritmaskoj skali, kroz 8 mjerenja. Takvim mjerenjem obuhvaćeno je od 5% do 80% svojstvenih vektora. Optimalni rezultati postignuti su u dimenziji potprostora $D_{PCA}=100$ ili $D_{PCA}=90$. Postupak variranja dimenzionalnosti transformacije PCA računski je najviše zahtjevan jer se određivanje prostora transformacije interno provodi u nekoliko koraka:

- izračunava se korelacijska matrica, R (prostorno i vremenski zahtjevno)
- izračunavaju se svojstvene vrijednosti i svojstveni vektori
- odabire se n svojstvenih vrijednosti i njima pripadnih svojstvenih vektora
- odabrani svojstveni vektori čine bazu novog vektorskog prostora

Važno je napomenuti da je odabir dimenzionalnosti transformacije PCA izrazito važan jer to je faktor koji utječe na složenost modela. Ukoliko je dimenzija transformacije visoka, tada će PCA metoda ud svakog uzoraka uzeti velik dio komponenti (na $D_{PCA}=1000$, $r=80\%$) i LDA će savršeno separirati razrede uzoraka, a disperzija razreda uzoraka bit će jako mala. Međutim, takav model je prenaučen i točnost klasifikacije na takvom modelu ne prelazi 50%. Određivanje optimalne dimenzije potprostora transformacije određeno je unakrsnom validacijom.

Tablica 4.1: Točnost klasifikacije u ovisnosti o dim. potprostora trans. PCA za jedan okvir

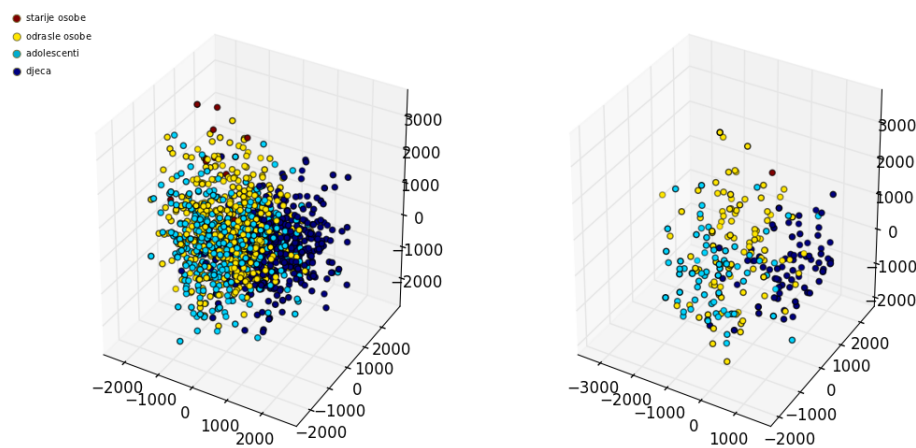
Br. okvira = 1	Dimenzionalnost potprostora transformacije								
klasifikator	20	50	75	80	90	100	150	200	1000
kNN	65%	66%	68%	70%	72%	73%	68%	67%	60%
SVM_{RBF}	50%	53%	58%	60%	60%	62%	71%	68%	33%
SVM_{POLY}	56%	61%	63%	65%	67%	68%	69%	67%	41%

Prilikom variranja broja okvira, ustanovljeno je da kNN klasifikator postiže najbolje rezultate klasifikacije, stoga je broj okvira fortgafije, obzirom na dimenzionalnost transformacije PCA variran samo za kNN.

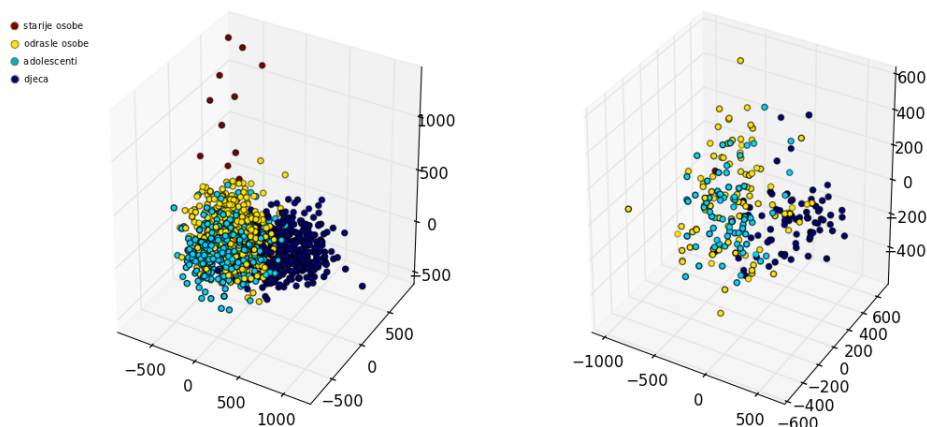
Tablica 4.2: Točnost klasifikacije u ovisnosti o dimenzionalnosti potprostora transformacije PCA za 4 okvira

Br. okvira = 4	Dimenzionalnost potprostora transformacije						
klasifikator	20	50	75	80	90	100	150
kNN	70%	70%	75%	75%	76%	76%	68%
Kbest	9	15	51	45	19	41	40

Zbog disperzivnosti u 3D prostoru, izabrali smo kao referentni iznos $k=41$, a referentnu dimenzionalnost transformacije PCA, $D_{PCA}=100$. Slike 4.4 i 4.5 prikazuju smanjenje i povećanje disperzije uzoraka u ovisnosti o prostoru dimenzionalnosti transformacije PCA. Razlog povećanju, odnosno smanjenju, disperzivnosti je udio svojstvenih vektora koji sudjeluju u transformaciji uzorka. Ukoliko je uzorak opisan s više svojstava, LDA metoda će pronaći bolje parametre (sredinu razreda i ukupnu sredinu uzoraka) te će bolje grupirati uzorke u 3D.

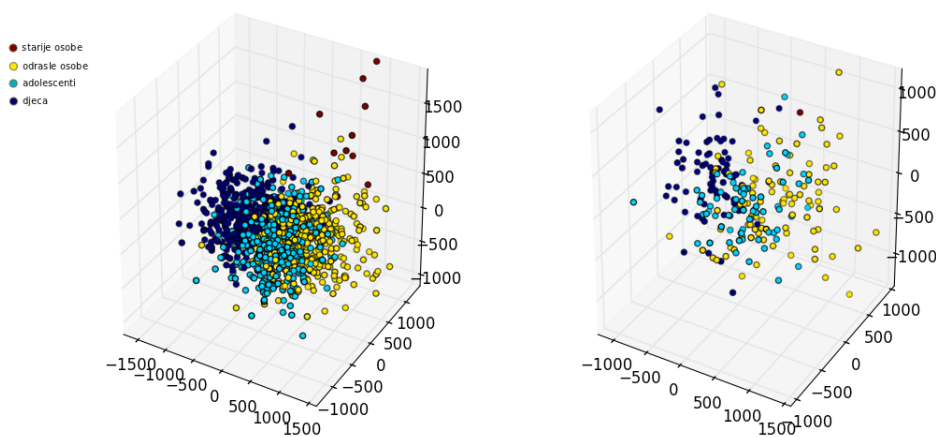


Slika 4.4: Lijeva slika prikazuje uzorke za učenje u 3D, a desna slika prikazuje uzorke za testiranje; $D_{PCA}=20$



Slika 4.5: Lijeva slika prikazuje uzorke za učenje u 3D, a desna slika prikazuje uzorke za testiranje; $D_{PCA}=200$

Uzorke u $D_{PCA}=100$ prikazuje Slika 4.6. Zbog optimalnih rezultata, u daljnjim testiranjima korištena dimenzija transformacije PCA je $D_{PCA}=100$.

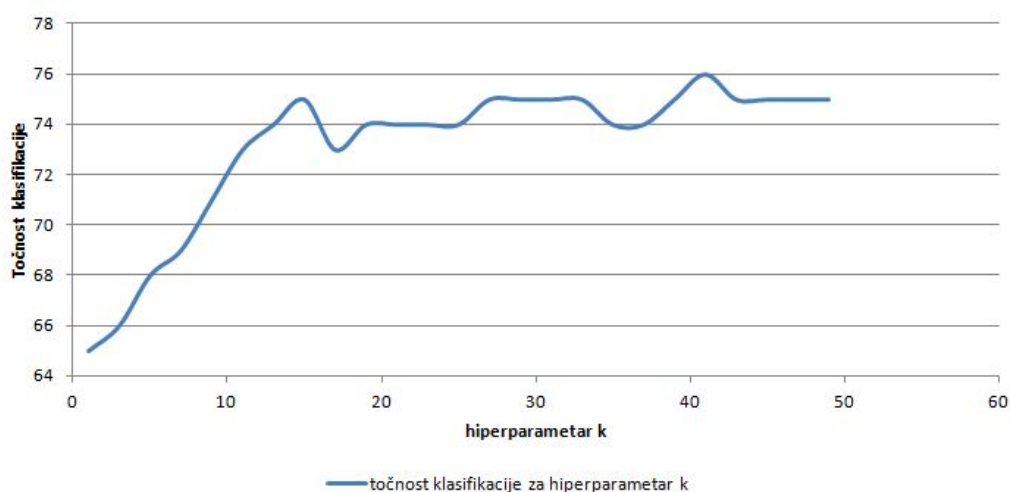


Slika 4.6: Lijeva slika prikazuje uzorke za učenje u 3D, a desna slika prikazuje uzorke za testiranje; $D_{PCA}=100$

Iz slika (4.4, 4.5 i 4.6) pokazuje se da je dimenzija $D_{PCA}=100$ najbolja jer uzorci iz skupa za testiranje su separatibilni dovoljno da pogaška klasifikacije bude manja nego pri transformaciji u više- ili niže-(PCA)dimenzionalan prostor.

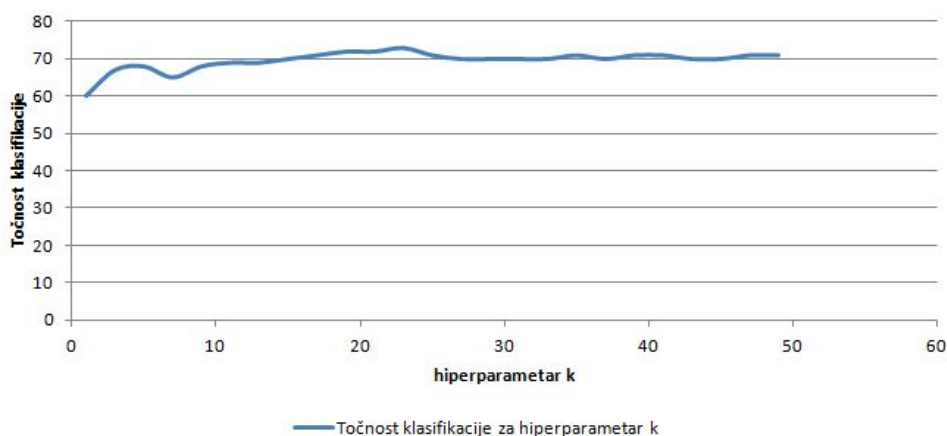
4.2.2. Parametar k klasifikatora kNN, korištenjem euklidske udaljenosti

Osim LDA metode, napisana je metoda koja implementira klasifikator kNN. Unakrsnom validacijom određen je hiperparametar k koji određuje broj najbližih primjera, iz skupa za učenje, primjeru iz skupa za testiranje, da bi isti bio ispravno klasificiran. Graf 4.7 prikazana je točnost klasifikacije u ovisnosti o veličini parametra k, uz broj okvira = 4 i $D_{PCA}=100$.



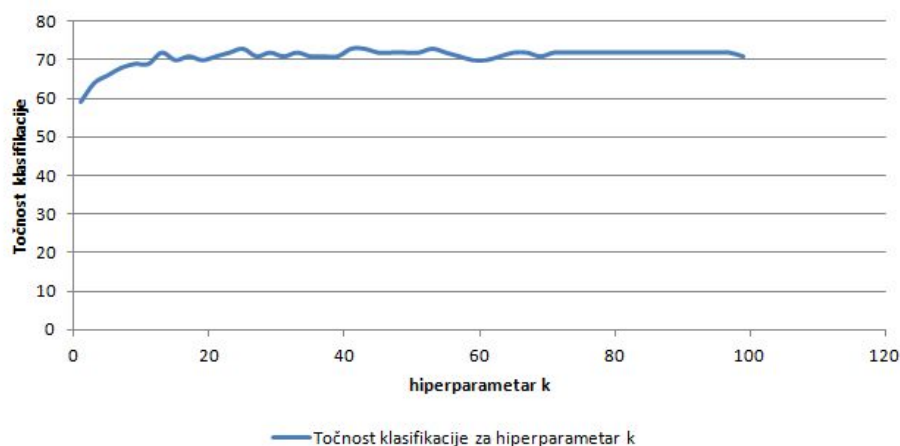
Slika 4.7: Točnost klas. u unakrsnoj validaciji za različite hiperparametre k, br. okvira=4

Točnost klasifikacije, ukoliko je broj okvira forografije jednak 16, prikazan je grafom 4.8.



Slika 4.8: Točnost klas. u unakrsnoj validaciji za različite hiperparametre k, br. okvira=16

Ukoliko je broj okvira jednak 1, tada je točnost klasifikacije prikazana grafom 4.9.



Slika 4.9: Točnost klas. u unakrsnoj validaciji za različite hiperparametre k, br. okvira=1

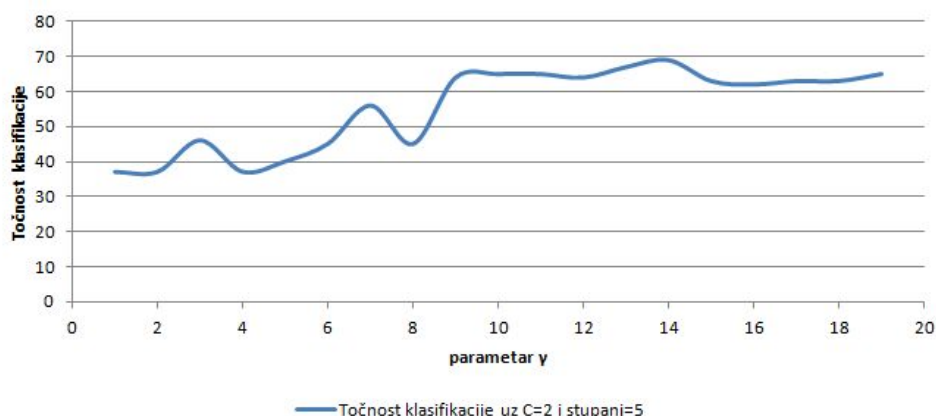
Najbolji rezultati klasifikacije postignuti su ukoliko je broj prozora jednak 4, $D_{PCA}=100$ i $k=41$.

4.2.3. Parametri klasifikatora SVM s polinomijalnom jezgrenom funkcijom

Polinomijalna jezgra određena je formulom 4.1.

$$K(x_i, x_j) = (\gamma * x_i^T * x_j + b)^p, \text{ uz uvjet } b > 0 \quad (4.1)$$

Kao parametar b postavljena je pretpostavljena vrijednost 1. Unakrsnom validacijom optimirali su se parametri γ i p (stupanj polinoma). Najmanja pogreška generalizacije, na skupu za testiranje, postignuta je za peti stupanj polinoma i $\gamma = 18$, optimalan regularizacijski parametar C jednak je 5, $D_{PCA}=150$ i broj okvira jednak 1. Graf 4.10 prikazuje točnost klasifikacije u ovisnosti o parametru γ , uz prethodno navedene iznose ostalih parametara.



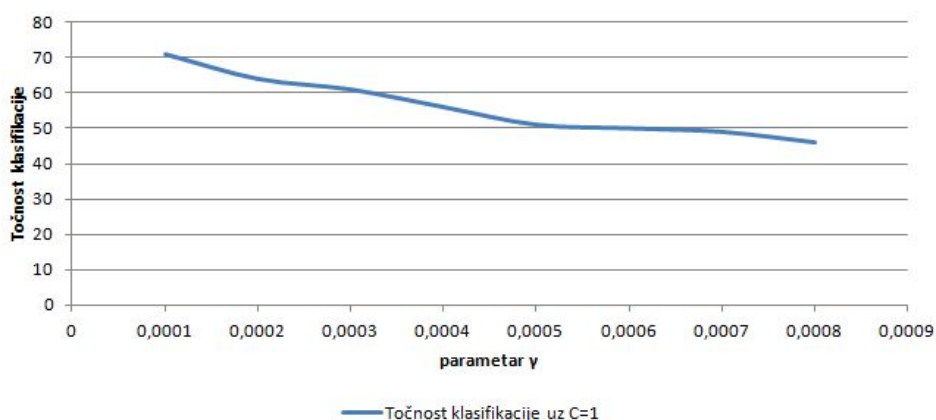
Slika 4.10: Točnost klas. u unakrsnoj validaciji za različite parametre γ , br. okvira=1, C=2, p=5

4.2.4. Parametri klasifikatora SVM s jezgrom radijalne bazne funkcije

Jezgra radijalne bazne funkcije određena je formulom 4.2.

$$K(x_i, x_j) = e^{-\gamma \|x_i - x_j\|^2}, \text{ uz uvjet } \gamma > 0 \quad (4.2)$$


Unakrsnom validacijom optimirali su se parametri γ i regularizacijski parametar SVM klasifikatora, C. Najmanja pogreška generalizacije, na skupu za testiranje, postignuta je za $\gamma = 0.0001$, optimalan regularizacijski parametar C jednak je 1, $D_{PCA} = 150$ i broj okvira jednak 1. Graf 4.11 prikazuje točnost klasifikacije u ovisnosti o parametru γ , uz prethodno navedene iznose ostalih parametara.



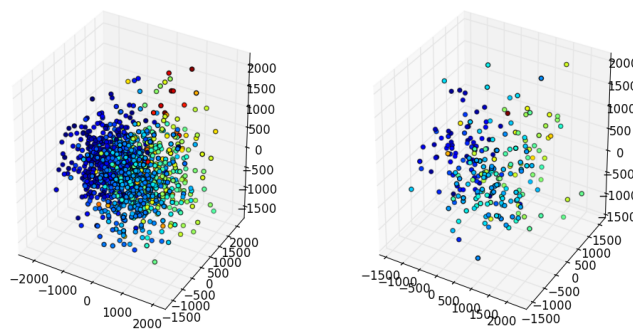
Slika 4.11: Točnost klas. u unakrsnoj validaciji za različite parametre γ , br. okvira=1, C=1

4.2.5. Objektivnost apriorno definiranih dobnih granica

Dobne granice razreda određene su subjektivnim kriterijem članova tima. Pritom κ (kappa koeficijent, Krippendorff 1980.) iznosi 1, što izražava potpuno slaganje članova tima s dobrnim granicama. Vizualizacijom uzoraka u 3D utvrđeno je da su dobne granice uzoraka odabrane vrlo dobro jer uzorci istih razreda pripadaju istim grupama i odskakanja uzoraka jednog razreda među uzorke drugih razreda su malene. Slike 4.12, 4.13, 4.14 i 4.15 prikazuju uzorke za učenje i uzorke za testiranje kolorirane prema dobnim granicama, uz različitu dimenziju PCA transformacije.

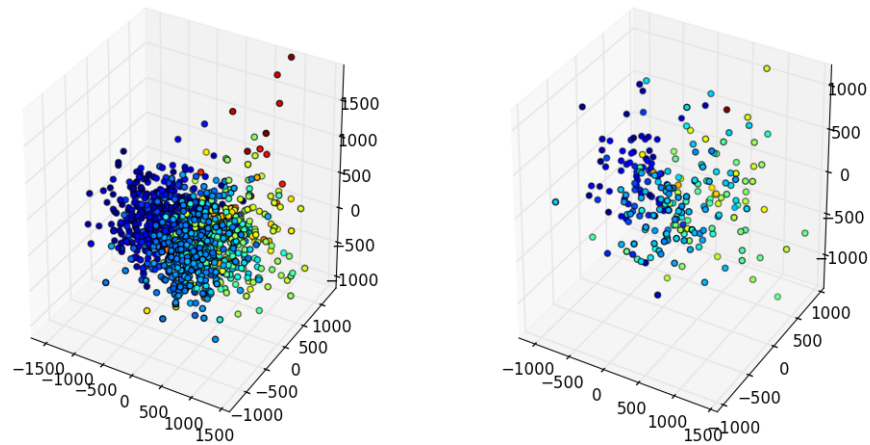


Slika 4.12: Kolorirani uzorci prema dobnim granicama. Lijevo su uzorci za učenje, a desno uzorci za testiranje. $D_{PCA}=20$

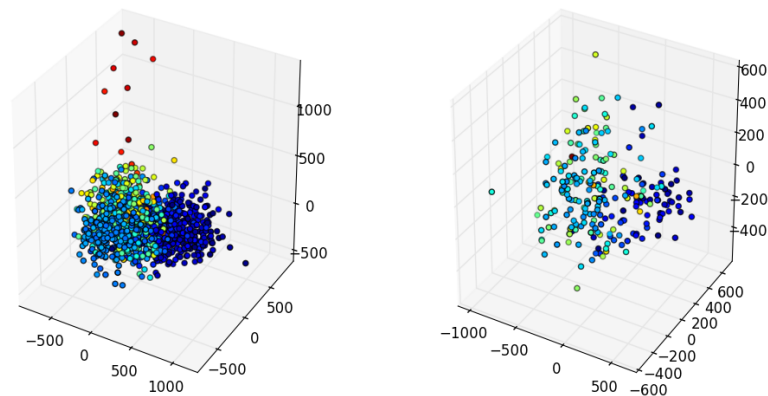


Slika 4.13: Kolorirani uzorci prema dobnim granicama. Lijevo su uzorci za učenje, a desno uzorci za testiranje. $D_{PCA}=50$

Ukoliko se slike (4.12, 4.13, 4.14 i 4.15) usporede sa slikama (4.4, 4.5 i 4.6), jasno se primjećuje da su dobne granice dobro odabrane jer uzorci jednakih boja zaista i čine jednake razrede.




Slika 4.14: Kolorirani uzorci prema dobnim granicama. Lijevo su uzorci za učenje, a desno uzorci za testiranje. $D_{PCA}=100$



Slika 4.15: Kolorirani uzorci prema dobnim granicama. Lijevo su uzorci za učenje, a desno uzorci za testiranje. $D_{PCA}=200$

4.2.6. Broj okvira fotografije

Radi što većeg prikupljanja informacija prilikom PCA i LDA metoda, fotografija je podijeljena u nekoliko okvira (dijelova). Unakrsnom validacijom, koristeći prethodno navedene klasifikatore, odabran je optimalan broj okvira za sve klasifikatore. Optimalan broj okvira za klasifikator kNN je 4. Slika 4.16 prikazuje način podjele izvorne fotografije na 4 i 16 okvira. Nad svakim okvirom provodi se zasebno PCA i LDA metoda.



Slika 4.16: Dijeljenje fotografije na okvire

Ukoliko se fotografija dijeli na okvire, povećava se i računska, prvenstveno vremenska, složenost izračunavanja. Tablica 4.3 prikazuje vremensko trajanje izračunavanja matrica transformacija postupka MDF (PCA i LDA) u ovisnosti o broju okvira fotografije (procesor Turion 64, dual core, 2.1 GHz).

Tablica 4.3: Vremensko trajanje izračunavanja postupka MDF obzirom na broj okvira

Broj okvira	Trajanje izračunavanja
1	12 min
4	50 min
16	75 min

4.3. Analiza rezultata

Kao najbolji klasifikator odabran je kNN, s parametrima navedenim u poglavlju 4.2. Za sve klasifikatore, za optimalne parametre, određena je matrica zabune i izračunate F_1^{makro} i F_1^{mikro} . Rezultate smatramo prihvatljivim obzirom da prvi puta implementiramo ovako složen sustav. Da je baza za učenje i testiranje sadržavala veći udio starijih osoba, postotak uspješnosti bio bi još veći.

4.3.1. Klasifikator kNN

Tablica 4.4 prikazuje matricu zabune klasifikatora kNN, s parametrima navedenim u poglavlju 4.2. Tablica 4.5 prikazuje izračunate evaluacijske mjere.

Tablica 4.4: Matrica zabune kNN klasifikatora

Matrica zabune	Stvarno				
	Razredi	Dijete	Adolescent	Odrasla o.	Starija o.
	Dijete	66	2	7	0
Predviđeno	Adolescent	6	52	21	0
	Odrasla o.	3	17	66	1
	Starija o.	0	0	0	0

Tablica 4.5: Evaluacijske mjere kNN klasifikatora

F_1^{makro}	F_1^{mikro}	Preciznost	Odziv
57.57%	76.39%	76.39%	76.39%

4.3.2. Klasifikator SVM s polinomijalnom jezgrenom funkcijom

Tablica 4.6 prikazuje matricu zabune klasifikatora SVM s polinomijalnom jezgrenom funkcijom, s parametrima navedenim u poglavlju 4.2. Tablica 4.7 prikazuje izračunate evaluacijske mjere.

Tablica 4.6: Matrica zabune SVM klasifikatora, s polinomijalnom jezgrenom funkcijom

Matrica zabune	Stvarno				
	Razredi	Dijete	Adolescent	Odrasla o.	Starija o.
	Dijete	63	4	7	0
Predviđeno	Adolescent	6	43	24	0
	Odrasla o.	3	24	61	1
	Starija o.	0	0	0	0

Tablica 4.7: Evaluacijske mjere SVM klasifikatora, s polinomijalnom jezgrenom funkcijom

F_1^{makro}	F_1^{mikro}	Preciznost	Odziv
52.43%	69.29%	69.29%	69.29%

4.3.3. Klasifikator SVM s jezgrom radijalne bazne funkcije

Tablica 4.8 prikazuje matricu zabune klasifikatora SVM s jezgrom radijalne bazne funkcije, s parametrima navedenim u poglavlju 4.2. Tablica 4.9 prikazuje izračunate evaluacijske mjere.

Tablica 4.8: Matrica zabune SVM klasifikatora, s jezgom radijalne bazne funkcije

Matrica zabune	Stvarno				
	Razredi	Dijete	Adolescent	Odrasla o.	Starija o.
	Dijete	56	1	1	0
Predviđeno	Adolescent	7	42	19	0
	Odrasla o.	12	28	74	1
	Starija o.	0	0	0	0

Tablica 4.9: Evaluacijske mjere SVM klasifikatora, s polinomijalnom jezgrenom funkcijom

F_1^{makro}	F_1^{mikro}	Preciznost	Odziv
53.86%	71.37%	71.37%	71.37%

4.3.4. Moguća poboljšanja

Prvenstveno su moguća poboljšanja u vrijednostima parametara i hiperparametara klasifikatora, čime bi se postotak točno klasificiranih primjera za učenje znatno poboljšao. Predlaže se bolji izbor baze fotografija, s uniformno raspoređenim osobama raznih dobnih skupina. Predlaže se metoda grupiranja (algoritam K-srednjih vrijednosti ili EM-algoritam) koja bi automatski odredila najpouzdanije dobne granice uzoraka. Smatramo da je MDF postupak (PCA + LDA) dobar za raspoznavanje dobne skupine osobe na temelju lica, ali parametri postupka moraju biti vrlo pažljivo odabrani i baza fotografija za učenje mora sadržavati uniformno zastupnjene fotografije svih dobnih skupina.

5. Zaključak

U ovome radu prezentirana je implementacija sustava za raspoznavanje dobnih skupina na temelju lica korištenjem linearne diskriminantne analize (LDA). Ovaj sustav klasificira uzorke (slike lica pojedine osobe) u jednu od 4 skupine (djeca, adolescenti, odrasle osobe i starije osoba). Nad skupom za učenje je zbog smanjenja dimenzionalnosti uzoraka (prvotno $128 \times 128 = 16384$) prvo provedena analiza glavnih komponenti (PCA), te su uzorci zatim pomoću LDA reducirani na dimenzionalnost $c-1=3$. Prilikom klasifikacije korištena su dva klasifikatora - k najbližih susjeda (kNN) te stroj s potpornim vektorima (SVM). Kako bi pronašli optimalne parametre (za koje sustav najtočnije klasificira skup za testiranje) pojedinih komponenti sustava provedena je unakrsna validacija. Analizom rezultata zaključili smo da je najveća točnost sustava 76%. Poboljšanje je moguće u vidu boljeg izbora baze fotografija, s uniformno raspoređenim osobama raznih dobnih skupina. Primjerice, ovakav sustav može biti korišten u trgovačkim lancima za analizu dobne raspodjele kupaca te time pomoći u boljem strateškom pozicioniranju proizvoda (ili možda povećanju ponude proizvoda koji privlače pojedine dobne skupine).

6. Literatura

- [1] Peter N. et al. Belhumeur. Eigenfaces vs. Fisherfaces: Recognition Using Class Specific Linear Projection. IEEE, vol. 19, NO. 7, 1997.
- [2] OpenCV Community. OpenCV Dokumentacija. <http://opencv.itseez.com/>, 2011.
- [3] Yun et al. Fu. Age Synthesis and Estimation via Faces: A Survey. IEEE, vol. 32, 2010.
- [4] Guodong et al. Guo. A Study on Automatic Age Estimation using a Large Database. IEEE, 12th International Conference on Computer Vision, 2009.
- [5] Slobodan Ribarić. *Uvod u raspoznavanje uzoraka: primjena računala i mikro-računala u sustavima za raspoznavanje uzoraka*. Tehnička knjiga, 1988. ISBN 9788670590540.